

Aprendizaje por Refuerzo

Métodos de Monte Carlo

LUIS DANIEL HERNÁNDEZ MOLINERO
CIENCIA DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL
DEPT. INGENIERÍA DE LA INFORMACIÓN Y LAS COMUNICACIONES

Universidad de Murcia

Máster en Inteligencia Artificial
2025 / 2026



1. Introducción
2. Métodos On-Policy
 - 2.1. Predicción On-policy MC
Evaluación de las funciones $v(s)$
 - 2.2. Control On-policy
Evaluación de las funciones $q(s, a)$
Iteración General de Políticas para MC
Con inicios exploratorios
Con políticas ϵ -soft
3. Métodos Off-Policy
 - 3.1. Predicción Off-policy MC
 - 3.2. Control Off-policy
4. Referencias

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

- ▶ **Programación Dinámica** requiere el conocimiento completo del proceso.
- ▶ Los **métodos de Monte Carlo** se caracterizan por:
 - ▶ Es ***sin modelo***: no requieren conocimiento previo de la dinámica del entorno
 - ▶ Requieren solo **experiencia**: conocimiento de trayectorias
 - ▶ Cualquier Monte Carlo usa **muestras** para realizar estimaciones.
 - ▶ Una muestra es finita: MC únicamente para **tareas episódicas**
 - ▶ **Solo al completar un episodio**, se estimarán los valores y se actualizan las políticas.
 - No utiliza *bootstrapping*.
- ▶ **Métodos de aprendizaje**:
 - ▶ **Métodos on-policy**: Evalúan o mejoran la política que se utiliza para tomar decisiones.
 - ▶ **Métodos off-policy**: Evalúan o mejoran una política diferente a la que se utiliza para generar los datos.

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias



Con más detalle ..

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

Evaluación de Políticas Monte-Carlo (On-Policy)

► Para **predicción**:

- Entrada: MDP $\langle S, A, P, R, \gamma \rangle$ y política π .
- Salida, función de valor v_π .

► En **Programación Dinámica**: $V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)[r + \gamma V(s')]$ (utiliza *bootstrapping*)

► Pero **también sabemos** que:

- Por definición, $v_\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]$ con $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ (**variable aleatoria**).

- Ley de los grandes números, $\mathbb{E}_\pi[G_t | s_t = s] \approx \frac{1}{N} \sum_{i=1}^N G_t^{(i)}$. $P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$,

► **Objetivo MC**: Aprender v_π a partir de episodios de experiencia bajo la política π .

1. Soltar al agente en S_0 .
2. Obtener un episodio: $S_0, A_1, R_1, \dots, S_T, R_T \sim \pi$.
3. Calcular su retorno: $G_0 = R_1 + \gamma R_2 + \dots + \gamma^{T-1} R_T$
4. Repetir varias veces los 3 pasos anteriores.
5. Retornar el promedio de los retornos.

$$\underbrace{S_0, S_1, R_1, \overbrace{S_2, R_2, S_3, R_3 \dots, S_T, R_T}^{G_1}}_{G_0}$$

Usamos el Proceso de Recompensas de Markov

► Evaluación de Primera Visita (First-Visit)

$$S_0, S_1, R_1, \dots, \underbrace{S_i, R_i, \dots, S_i, R_i, \dots, S_T, R_T}_{G_i}$$

- Para evaluar el estado s :
 - **Identifica el primer instante** de tiempo t en el que el estado s es visitado en un episodio.
 - Incrementa el contador $N(s) \leftarrow N(s) + 1$.
 - Incrementa el retorno total $S(s) \leftarrow S(s) + G_t$.
- El valor se estima como el retorno promedio: $V(s) = \frac{S(s)}{N(s)}$.
- Según la ley de los grandes números, $V(s) \rightarrow v_\pi(s)$ a medida que $N(s) \rightarrow \infty$.

► Evaluación de Todas las Visitas (Every-Visit)

$$S_0, S_1, \dots, \underbrace{S_i, R_i, \dots, S_i, R_i, \dots, S_T, R_T}_{G_i}^{G'_i}$$

- Para evaluar el estado s :
 - **En cada instante** de tiempo t en el que el estado s es visitado en un episodio:
 1. Incrementa el contador $N(s) \leftarrow N(s) + 1$.
 2. Incrementa el retorno total $S(s) \leftarrow S(s) + G_t$.
- El valor se estima como el retorno promedio: $V(s) = \frac{S(s)}{N(s)}$.
- Nuevamente, $V(s) \rightarrow v_\pi(s)$ a medida que $N(s) \rightarrow \infty$. (Singh & Sutton, 1996)

► Actualización incremental: $N(s) \leftarrow N(s) + 1$, $V(s) \leftarrow V(s) + \frac{1}{N(s)}(G_t - V(s))$

Algorithm 1 Predicción MC de primera visita, para estimar $V \approx v_\pi$

First-visit MC prediction, for estimating $V \approx v_\pi$

Input: a policy π to be evaluated

Initialize:

$V(s) \in \mathbb{R}$, arbitrarily, for all $s \in \mathcal{S}$

$Returns(s) \leftarrow$ an empty list, for all $s \in \mathcal{S}$

Loop forever (for each episode):

Generate an episode following π : $S_0, A_0, R_1, S_1, A_1, R_2, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless S_t appears in $S_0, S_1, \dots, S_{t-1}$:

Append G to $Returns(S_t)$

$V(S_t) \leftarrow \text{average}(Returns(S_t))$



Resumen. Predicción Monte Carlo

- ▶ Los métodos Monte Carlo **no usan *bootstrapping***.
 - ▶ La estimación para un estado no se construye a partir de la estimación de ningún otro estado, como ocurre en la Programación Dinámica (DP).
- ▶ El costo computacional de estimar el valor de un solo estado **es independiente** del número total de estados.
- ▶ Los métodos Monte Carlo son particularmente **atractivos** cuando se requiere el valor de ***solo uno o un subconjunto de estados***.

Ejemplo de Blackjack

▣ Estados (200 en total):

- ▶ Suma actual (12-21).
- ▶ Carta visible del dealer (as-10).
- ▶ ¿Tengo un as "utilizable"? (sí-no).

▣ Acciones:

- ▶ *Pedir*: recibir otra carta (sin reemplazo).
- ▶ *Plantarse*: detenerse y terminar.

▣ Recompensa al plantarse:


- ▶ **+1** si la suma de cartas del jugador es mayor que la suma de cartas del croupier.
- ▶ **0** si las sumas son iguales.
- ▶ **-1** si la suma del jugador es menor que la suma del croupier.

▣ Recompensa al pedir:

- ▶ **-1** si la suma de cartas del jugador > 21 (termina el juego).
- ▶ **0** en caso contrario.

▣ Transiciones: automáticamente pide si la suma de cartas del jugador < 12 .

▣ Política: plantarse si la suma de cartas ≥ 20 , de lo contrario pedir.



1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias



Con más detalle ..

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

Evaluación de Funciones $q()$ (Control)

► Para **control**:

- Entrada: MDP $\langle S, A, P, R, \gamma \rangle$.
- Salida: función de valor óptima $v^*(s)$ y política óptima $\pi^*(s)$

► Para **Programación Dinámica**: $\pi'(s) \leftarrow \arg_a \max q_\pi(s, a) = \arg \max_a \sum_{s', r} p(s', r | s, a) [r + \gamma V(s')]$

► Pero **también sabemos** que:

- Por definición, $q_\pi(s, a) = \mathbb{E}_\pi [G_t | s_t = s, a_t = a]$ con $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$
- Ley de los grandes números: $\mathbb{E}_\pi [G_t | s_t = s, a_t = a] \approx \frac{1}{N} \sum_{i=1}^N G_t^{(i)}$ $P \left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu \right) = 1$,

► **Objetivo MC**: Aprender q_π a partir de episodios de experiencia bajo la política π .

► Ahora en vez de tener en cuenta el estado, hay que tener en cuenta (estado, acción)

$$\underbrace{s_0, a_0, R_1, s_1, a_1 \dots s_i, a_i, \overbrace{R_{i+1}, s_{i+1}, \dots, R_T, s_T}}^{G_i(s_i, a_i)}}_{G_0(s_0, a_0)}$$

- Se visita un par estado–acción (s, a) en un episodio si el estado s se visita y la acción a se toma en él.
- El método MC de **todas las visitas** estima el valor de un par estado–acción como el promedio de los retornos que siguieron a todas las visitas a este.
- El método MC de **primera visita** promedia los retornos que siguieron a la primera vez en cada episodio en que el estado fue visitado y la acción seleccionada.
- Ambos convergen a los valores esperados verdaderos.

Hay problemas

- ▶ Se tiene un **problema de exploración** (como en bandido k-brazos)
P.e. Si π es una **política determinista**

- ▶ Algunos pares estado-acción pueden no ser visitados nunca.
- ▶ Así es imposible saber si hay alternativas posibles.

▶ Soluciones:

- ▶ Inicios exploratorios: $s_0 \sim \text{rnd}(\mathcal{S})$ y $a_0 \sim \text{rnd}(\mathcal{A}(s_0))$
- ▶ Políticas estocásticas: $\pi(s|a) > 0 \quad \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$



Con más detalle ..

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft



3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

Iteración de Políticas General



- La idea general de la **Iteración de Políticas**:

$$\pi_0 \xrightarrow{E} v_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} v_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} v_*$$

- **Versión Monte Carlo** de la iteración clásica de políticas.

$$\pi_0 \xrightarrow{E} q_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} q_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} q_*$$

- **Evaluación:** Simulación por muestras de cada $q_{\pi_k}(s, a)$
- **Mejora:** $\pi_{k+1}(s) = \arg \max_a q_{\pi_k}(s, a)$
- **Hipótesis:** un número infinito de episodios + los episodios *se generan con inicios exploratorios*.
 - los métodos de Monte Carlo calcularán cada q_{π_k} exactamente, para π_k arbitrarias.
 - Se sigue cumpliendo el teorema de mejora de políticas
Como $q_{\pi_k}(s, \pi_{k+1}(s)) \geq v_{\pi_k}(s)$, entonces $v_{\pi_{k+1}}(s) \geq v_{\pi_k}(s)$ (π_{k+1} es tan buena como π_k)
- **En la práctica** renunciamos al número infinito de episodios (Renunciamos a una evaluación exacta).

$$\pi_0 \xrightarrow{E} Q_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} Q_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} q_*$$



Con más detalle ..

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

Algorithm 2 Monte Carlo ES (Exploring Starts), para estimar $\pi \approx \pi_*$

Monte Carlo ES (Exploring Starts), for estimating $\pi \approx \pi_*$

Initialize:

$\pi(s) \in \mathcal{A}(s)$ (arbitrarily), for all $s \in \mathcal{S}$

$Q(s, a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

$Returns(s, a) \leftarrow$ empty list, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

Loop forever (for each episode):

Choose $S_0 \in \mathcal{S}$, $A_0 \in \mathcal{A}(S_0)$ randomly such that all pairs have probability > 0

Generate an episode from S_0, A_0 , following π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$:

Append G to $Returns(S_t, A_t)$


$Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$

$\pi(S_t) \leftarrow \operatorname{argmax}_a Q(S_t, a)$

- ▶ Los returns se acumulan **independientemente** de la política que los observó.
- ▶ No converge a una política subóptima

Resolver el Blackjack por MC

- ▶ Queremos resolver Blackjack por MC-ES
- ▶ Para garantizar la exploración completa:
 - ▶ Se seleccionan al azar las cartas del crupier.
 - ▶ Se elige la suma inicial del jugador.
 - ▶ Se determina si el jugador tiene o no un as utilizable.
 - ▶ Todas las combinaciones posibles se generan con igual probabilidad.
- ▶ Política inicial: Se planta solo con sumas de 20 o 21, de lo contrario pedir.
- ▶ Los valores iniciales de la función de valor de acción ($Q(s, a)$) se establecen en cero para todos los pares estado-acción.
- ▶ El jugador aplica una política diferente dependiendo de si tiene o no un as utilizable.





Con más detalle ..

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

► **Recuerda.** Las soluciones para garantizar que sean seleccionados los pares (estado, acción):

- **Inicios exploratorios:** $s_0 \sim \text{rnd}(S)$ y $a_0 \sim \text{rnd}(\mathcal{A}(s_0))$
- **Políticas estocásticas:** $\pi(s|a) > 0 \quad \forall s \in S, \forall a \in \mathcal{A}$

► **Política suave (soft-policy):** $\pi(a|s) > 0$ para todos los $s \in S$ y $a \in \mathcal{A}$.

► **Política ϵ -soft:** $\pi(a|s) \geq \frac{\epsilon}{|\mathcal{A}(s)|}$ para todos los $s \in S$ y $a \in \mathcal{A}$, donde $\epsilon > 0$.

La acción codiciosa (greedy) se selecciona con probabilidad: $1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|}$ mientras que una acción no codiciosa específica se selecciona con probabilidad: $\frac{\epsilon}{|\mathcal{A}(s)|}$.

► **Las políticas ϵ -greedy son políticas ϵ -soft**

$$a^* \leftarrow \begin{cases} \arg \max_a Q_\pi(s, a) & \text{con probabilidad } 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \\ \text{acción no greedy} & \text{con probabilidad } \frac{\epsilon}{|\mathcal{A}(s)|} \end{cases} \quad (\text{rompiendo aleatoriamente})$$

► **Generalized Policy Iteration (GPI):** No requiere que la política se lleve completamente a una política-greedy, solo que se mueva en dirección hacia una política-greedy, de forma análoga a que tampoco evaluamos completamente las funciones de valor.

La Iteración de Políticas Funciona para Políticas Greedy sobre Políticas ϵ -soft.



- Cualquier política π' que sea ϵ -greedy con respecto a q_π es una mejora sobre cualquier política ϵ -soft, π ,
 - Se cumple que: $q_\pi(s, \pi'(s)) \geq v_\pi(s)$

$$\begin{aligned} q_\pi(s, \pi'(s)) &= \sum_a \pi'(a|s) q_\pi(s, a) \\ &= \frac{\epsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + (1 - \epsilon) \max_a q_\pi(s, a) \\ &\geq \frac{\epsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + (1 - \epsilon) \sum_a \left(\pi(a|s) - \frac{\epsilon/|\mathcal{A}(s)|}{1 - \epsilon} \right) q_\pi(s, a) \\ &= \frac{\epsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) - \frac{\epsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + \sum_a \pi(a|s) q_\pi(s, a) \\ &= v_\pi(s). \end{aligned}$$

- Por el teorema de mejora de políticas, $\pi' \succeq \pi$ (es decir, $v_{\pi'}(s) \geq v_\pi(s)$ para todo $s \in S$).
- $v_{\pi'}(s) = v_\pi(s)$ para todo $s \in S$ solo cuando **tanto π' como π son óptimas entre las políticas ϵ -soft**; es decir, cuando son mejores o iguales que todas las demás políticas ϵ -soft (Sutton & Barto, 2018).

Iteración de Valor versión Monte Carlo con Políticas ϵ -soft

Algorithm 3 On-policy Control Monte Carlo de primera visita (para políticas ϵ -soft)

On-policy first-visit MC control (for ϵ -soft policies), estimates $\pi \approx \pi_*$

Algorithm parameter: small $\epsilon > 0$

Initialize:

$\pi \leftarrow$ an arbitrary ϵ -soft policy

$Q(s, a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

$Returns(s, a) \leftarrow$ empty list, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

Repeat forever (for each episode):

Generate an episode following π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$:

Append G to $Returns(S_t, A_t)$

$Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$

$A^* \leftarrow \arg\max_a Q(S_t, a)$ (with ties broken arbitrarily)

For all $a \in \mathcal{A}(S_t)$:

$$\pi(a|S_t) \leftarrow \begin{cases} 1 - \epsilon + \epsilon/|\mathcal{A}(S_t)| & \text{if } a = A^* \\ \epsilon/|\mathcal{A}(S_t)| & \text{if } a \neq A^* \end{cases}$$

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias

Métodos off-Policy

- ▶ **Métodos off-policy:** Evalúan o mejoran una política diferente a la que se utiliza para generar los datos.
- ▶ **En consecuencia**, dado que los datos provienen de una política diferente, los métodos off-policy generalmente:
 - ▶ Sufren de mayor varianza.
 - ▶ Son más lentos para converger.
- ▶ **Son más** poderosos y generales.
 - ▶ Los métodos on-policy son un caso especial.
- ▶ Pueden aplicarse para **aprender a partir de datos generados** por un controlador convencional no basado en aprendizaje, o por un experto humano.

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC


3.2. Control Off-policy

4. Referencias

- Consideremos el problema de predicción, en el cual tanto la **política objetivo** (π , *target policy*) como la **política de comportamiento** (b , *behavior policy*) están fijas.
 - Queremos estimar v_π o q_π , pero solo tenemos episodios generados siguiendo la política b , donde $b \neq \pi$.
- $b()$ debe cumplir ciertas condiciones.
 - **Suposición de cobertura:** Toda acción tomada bajo π también debe tomarse, al menos ocasionalmente, bajo b .
$$\pi(a|s) > 0 \implies b(a|s) > 0.$$
 - $b()$ debe ser **estocástica**.

A pesar de que $\pi(a|s) = 0$, debe cumplirse $b(a|s) > 0$.
- Casi todos los métodos *off-policy* utilizan el **muestreo de importancia** (esquema general):
 - Queremos calcular un valor esperado bajo una distribución objetivo π : $\mathbb{E}_\pi[f(x)] = \int f(x)\pi(x)dx$,
 - Podemos expresarlo como $\mathbb{E}_\pi[f(x)] = \int f(x) \frac{\pi(x)}{b(x)} b(x)dx = \int f(x)w(x)b(x)dx$, con $w(x) = \frac{\pi(x)}{b(x)}$.
 - **Coefficiente de muestreo de importancia:** $w(x)$
 - $\mathbb{E}_\pi[f(x)] = \mathbb{E}_b[f(x) \cdot w(x)]$

► Entonces
$$\mathbb{E}_\pi[f(x)] \approx \frac{1}{N} \sum_{i=1}^N f(x_i)w(x_i) \text{ tomando muestras } x_i \sim b(x)$$



$$G_\pi(s) = w(s)G_b(s)$$

Adaptación del Muestreo por Importancia para Predicción

- **Nuestro objetivo** es estimar $v_\pi(s)$ muestreando con una política $b(s)$ y usando muestreo por importancia.
- Consideramos un **episodio aleatorio**: $H_{S_t} = A_t, S_{t+1}, A_{t+1}, \dots, S_T$
- **Las probabilidades** bajo las políticas π y b son:

$$\begin{aligned} \text{► } P(H_{S_t} \sim \pi) &= P_\pi\{A_t, S_{t+1}, A_{t+1}, \dots, S_T \mid S_t, A_{t:T-1}\} \\ &= \pi(A_t \mid S_t)p(S_{t+1} \mid S_t, A_t)\pi(A_{t+1} \mid S_{t+1}) \cdots p(S_T \mid S_{T-1}, A_{T-1}) \\ &= \prod_{k=t}^{T-1} \pi(A_k \mid S_k)p(S_{k+1} \mid S_k, A_k), \end{aligned}$$

$$\text{► } P(H_{S_t} \sim b) = \prod_{k=t}^{T-1} b(A_k \mid S_k)p(S_{k+1} \mid S_k, A_k)$$

- El **peso de importancia** (*importance-sampling ratio*) para un episodio es:

$$w(H_{S_t}) = \rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k \mid S_k)}{b(A_k \mid S_k)}.$$

- Reescribimos el valor esperado: $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_b[\rho_{t:T-1} G_t \mid S_t = s]$

Predicción Off-Policy con Muestreo por Importancia

- ▶ Los pasos de tiempo serán **consecutivos**. No se “resetea” para cada episodio.
- ▶ $\mathcal{T}(s)$ es el **conjunto de pasos de tiempo** en los que el estado s es visitado
 - ▶ **Primera Visita**: los pasos de tiempo en los que se realizaron las *primeras visitas* a s dentro de sus episodios
 - ▶ **Todas las Visitas**: *todos* los pasos de tiempo donde s fue visitado.
- ▶ $T(t)$: el **primer tiempo** de terminación posterior al tiempo t .
- ▶ G_t : el **retorno** después de t hasta $T(t)$.
- ▶ Luego, $\{G_t\}_{t \in \mathcal{T}(s)}$ son los **retornos relacionados** con el estado s
- ▶ $\{\rho_{t:T(t)-1}\}_{t \in \mathcal{T}(s)}$ son los correspondientes **coeficientes de muestreo por importancia**.
- ▶ **Muestreo por importancia ordinario**: Para estimar $v_\pi(s)$, escala los retornos por los coeficientes de muestreo por importancia y promedia los resultados:

$$V(s) = \frac{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{|\mathcal{T}(s)|}.$$

- ▶ **Muestreo de importancia ponderado**:

$$V(s) = \frac{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1}}, \text{ o cero si el denominador es cero.}$$

Comparación entre Muestreo de Importancia Ordinario y Ponderado




Características	Muestreo de Importancia Ordinario	Muestreo de Importancia Ponderado
Fórmula de Estimación	$V(s) = \frac{\sum_{t \in \mathcal{T}(s)} \rho_t \cdot T(t) - 1 G_t}{ \mathcal{T}(s) }$ Promedio simple de retornos escalados por las razones de importancia.	$V(s) = \frac{\sum_{t \in \mathcal{T}(s)} \rho_t \cdot T(t) - 1 G_t}{\sum_{t \in \mathcal{T}(s)} \rho_t \cdot T(t) - 1}$ Promedio ponderado de retornos escalados por las razones de importancia.
Primera Visita		
Sesgo	▶ No sesgado: $\mathbb{E}[V(s)] = v_\pi(s)$.	▶ Sesgado: $\mathbb{E}[V(s)] \approx v_b(s)$. ▶ El sesgo converge a cero asintóticamente.
Varianza	▶ Alta y potencialmente ilimitada: Depende de la variabilidad de las razones ρ. ▶ Puede ser extrema si ρ es grande (e.g., transparencia posterior).	▶ Menor varianza: Normalización reduce el impacto de ρ grandes. ▶ La varianza converge a cero si los retornos están acotados, incluso si $\text{Var}(\rho)$ es infinita.
Convergencia	▶ La expectativa está alineada con $v^\pi(s)$, pero con alta varianza puede requerir más muestras.	▶ Aunque sesgado, la menor varianza suele conducir a estimaciones más estables y eficientes en la práctica.
Preferencia Práctica	▶ Menos preferido debido a la alta varianza. ▶ Más fácil de extender a métodos aproximados usando aproximación funcional.	▶ Generalmente preferido en la práctica por su varianza significativamente menor. ▶ Usado comúnmente en algoritmos de Monte Carlo de todas las visitas.
Todas las Visitas	▶ Ambas variantes (ordinario y ponderado) son sesgadas en métodos de visita múltiple. ▶ El sesgo disminuye asintóticamente con el aumento del número de muestras.	Son preferidos "Todas las visitas" porque ▶ Eliminan la necesidad de llevar un registro de qué estados han sido visitados ▶ Son mucho más fáciles de extender a aproximaciones.

Estimación off-policy del valor de un estado en Blackjack

Curvas de aprendizaje



- ▶ Se aplicaron tanto métodos de **muestreo de importancia ordinario** como **muestreo de importancia ponderado** para estimar el valor de un único estado en Blackjack.
- ▶ Estado evaluado: $v_{\pi}(s) \approx 0,27726$ para 100 millones de episodios on-policy
 - ▶ $s = (\text{El crupier muestra un dos, La suma de las cartas del jugador es 13, El jugador tiene un as utilizable})$
- ▶ La **política de comportamiento** es pedir o plantarse con igual probabilidad.
- ▶ La **política objetivo** consiste en plantarse solo con una suma de 20 o 21.



$$ECM = \frac{1}{N} \sum_{i=1}^N (\hat{v}^{(i)}(s) - v_{\pi}(s))^2 \text{ Donde:}$$


- ▶ $N = 100$: Número de ejecuciones independientes.
- ▶ $\hat{v}^{(i)}(s)$: Estimación en la i -ésima ejecución.
- ▶ $v_{\pi}(s) = 0,27726$: Valor verdadero del estado.
- ▶ Convergen al valor verdadero después de **10,000 episodios**.

Varianza Infinita en Muestreo de Importancia Ordinario

- Las estimaciones del muestreo de importancia ordinario típicamente tienen **varianza infinita** si los retornos escalados tienen varianza infinita.

► Esto es común en aprendizaje *off-policy* si las trayectorias contienen bucles.

- Ejemplo:



$$\pi(\text{left}|s) = 1$$

$$b(\text{left}|s) = \frac{1}{2}$$

$$\triangleright v_\pi(s) = \mathbb{E}_\pi[G_t | S_t = s] = \mathbb{E}_b[\rho_{t:T-1} G_t | S_t = s]$$

$$\triangleright \text{Var}[X] = \mathbb{E}[(X - \bar{X})^2] = \mathbb{E}[X^2] - \bar{X}^2.$$

$$\begin{aligned} \triangleright \mathbb{E}_b \left[\left(\prod_{t=0}^{T-1} \frac{\pi(A_t|S_t)}{b(A_t|S_t)} G_0 \right)^2 \right] &= \\ &= \frac{1}{2} \cdot 0,1 \left(\frac{1}{0,5} \right)^2 \quad (\text{el episodio de longitud 1}) \\ &+ \frac{1}{2} \cdot 0,9 \cdot \frac{1}{2} \cdot 0,1 \left(\frac{1}{0,5 \cdot 0,5} \right)^2 \quad (\text{el episodio de longitud 2}) \\ &+ \frac{1}{2} \cdot 0,9 \cdot \frac{1}{2} \cdot 0,9 \cdot \frac{1}{2} \cdot 0,1 \left(\frac{1}{0,5 \cdot 0,5 \cdot 0,5} \right)^2 \quad (\text{el episodio de longitud 3}) \\ &+ \dots \\ &= 0,1 \sum_{k=1}^{\infty} \left(\frac{1}{2} \right)^k 0,9^{k-1} 2^{2k} = 0,1 \sum_{k=0}^{\infty} 0,9^k \cdot 2^k \cdot 2 = 0,2 \sum_{k=0}^{\infty} 1,8^k = \infty. \end{aligned}$$

► Existe **desalineación de políticas**: $b() \ll \pi()$.

- El algoritmo de **muestreo de importancia ponderado** resuelve este problema:

- Estimación de $V(s)$ es exactamente 1 después del primer episodio consistente.
- Los retornos inconsistentes (terminados con derecha) tienen una razón de muestreo de importancia de $\rho = 0$ y no contribuyen al cálculo.

Versión Incremental

► Estamos interesados en $V(s) = \mathbb{E}_\pi[G_t | S_t = s]$ y tenemos una secuencia de retornos $G_1, G_2, \dots, G_{n-1}$, todos comenzando en el mismo estado s .

► Generamos un episodio desde s , calculamos G_n y actualizamos V_{n+1} para todo $n \geq 1$.

► **On-policy:** $V(s) = \mathbb{E}_\pi[G_t | S_t = s] \approx V_n = \frac{\sum_{k=1}^{n-1} G_k}{n-1}$.

1. $V_{n+1} = V_n + \frac{1}{n} (G_n - V_n)$.

► **Off-policy ordinario:** $V(s) = \mathbb{E}_b[\rho_{t:T-1} G_t | S_t = s] \approx V_n = \frac{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1} G_k}{n-1} = \frac{\sum_{k=1}^{n-1} W_k G_k}{n-1}$.

1. $W_n = \rho_{t_n:T(t_n)-1}$

2. $V_{n+1} = V_n + \frac{1}{n} (W_n G_n - V_n)$

► **Off-policy ponderado:** $V(s) = \mathbb{E}_b[\rho_{t:T-1} G_t | S_t = s] \approx V_n = \frac{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1} G_k}{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1}} = \frac{\sum_{k=1}^{n-1} W_k G_k}{\sum_{k=1}^{n-1} W_k}$.

1. $W_n = \rho_{t_n:T(t_n)-1}$

2. $C_n = C_{n-1} + W_n$

3. $V_{n+1} = V_n + \frac{W_n}{C_n} (G_n - V_n)$

Predicción *Off-policy* MC todas las visitas para estimar $V \approx v_\pi$

Algorithm 4 Predicción fuera de política MC para estimar $V \approx v_\pi$

Entrada: una política objetivo arbitraria π

INICIALIZAR, para todos los $s \in S$:

$V(s) \in \mathbb{R}$ (inicializado arbitrariamente)

$C(s) \leftarrow 0$ (pesos acumulativos de muestreo de importancia)

while True, (para cada episodio) **do**

SELECCIONAR una política de comportamiento b con cobertura de π

GENERAR un episodio siguiendo b : $S_0, A_0, R_1, S_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$ # Inicializar el retorno acumulado

$W \leftarrow 1$ # Inicializar el peso acumulado

for cada paso del episodio en orden inverso $t = T - 1, T - 2, \dots, 0$, mientras $W \neq 0$: **do**

$G \leftarrow \gamma G + R_{t+1}$ # Actualizar el retorno acumulado

$C(S_t) \leftarrow C(S_t) + W$ # Actualizar el peso acumulado para S_t

$V(S_t) \leftarrow V(S_t) + \frac{W}{C(S_t)}[G - V(S_t)]$ # Actualización incremental del valor del estado S_t

$W \leftarrow W \cdot \frac{\pi(A_t|S_t)}{b(A_t|S_t)}$ # Actualizar el peso de importancia

end for

end while

1. $W_n = \rho_{t_n:T(t_n)-1}$
2. $C_n = C_{n-1} + W_n$
3. $V_{n+1} = V_n + \frac{W_n}{C_n} (G_n - V_n)$

Algorithm 5 Predicción MC off-Policy, para estimar $Q \approx q_\pi$

Off-policy MC prediction (policy evaluation) for estimating $Q \approx q_\pi$

Input: an arbitrary target policy π

Initialize, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$:

$Q(s, a) \in \mathbb{R}$ (arbitrarily)

$C(s, a) \leftarrow 0$

Loop forever (for each episode):

$b \leftarrow$ any policy with coverage of π

Generate an episode following b : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

$W \leftarrow 1$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$, while $W \neq 0$:

$G \leftarrow \gamma G + R_{t+1}$

$C(S_t, A_t) \leftarrow C(S_t, A_t) + W$

$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$

$W \leftarrow W \frac{\pi(A_t|S_t)}{b(A_t|S_t)}$

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC


3.2. Control Off-policy

4. Referencias

Control Monte Carlo Off-Policy

- ▶ Los métodos de control Monte Carlo **off-policy** **se caracterizan** porque
 - ▶ Siguen una **política de comportamiento** para aprender (experiencia, episodios), $b(a|s)$.
 - ▶ Mejoran una **política objetivo**, $\pi(a|s)$.
- ▶ **Condiciones** sobre la política de comportamiento $b()$:
 - ▶ Política de **comportamiento suave** (*soft*). $b(a|s) > 0 \forall a$
 - ▶ Cobertura. Si $\pi(a|s) > 0$, $b(a|s) > 0$.
 - ▶ Estocástica. Si $\pi(a|s) = 0$, $b(a|s) > 0$.
 - ▶ P.e. que sea ϵ -soft: $b(a|s) \geq \frac{\epsilon}{|\mathcal{A}(s)|}$ para todos los $s \in \mathcal{S}$ y $a \in \mathcal{A}$, donde $\epsilon > 0$.
- ▶ Nos basamos en el **Método de Iteración de Políticas General**:

- ▶ **Evaluación**
 - ▶ $b()$ será una política soft
 - ▶ Aplicar Predicción MC off-policy para estimar $Q \approx q_\pi$
- ▶ **Mejora**
 - ▶ Aplicar una política greedy sobre Q



Control Monte Carlo sin Inicios Exploratorios

Algorithm 6 Off-policy MC control para estimar $\pi \approx \pi_*$

Off-policy MC control, for estimating $\pi \approx \pi_*$

Initialize, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$:

$Q(s, a) \in \mathbb{R}$ (arbitrarily)

$C(s, a) \leftarrow 0$

$\pi(s) \leftarrow \operatorname{argmax}_a Q(s, a)$ (with ties broken consistently)

Loop forever (for each episode):

$b \leftarrow$ any soft policy

Generate an episode using b : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

$W \leftarrow 1$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

$C(S_t, A_t) \leftarrow C(S_t, A_t) + W$

$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$

$\pi(S_t) \leftarrow \operatorname{argmax}_a Q(S_t, a)$ (with ties broken consistently)

If $A_t \neq \pi(S_t)$ then exit inner Loop (proceed to next episode)

$W \leftarrow W \frac{1}{b(A_t|S_t)}$

1. Introducción

2. Métodos On-Policy

2.1. Predicción On-policy MC

Evaluación de las funciones $v(s)$

2.2. Control On-policy

Evaluación de las funciones $q(s, a)$

Iteración General de Políticas para MC

Con inicios exploratorios

Con políticas ϵ -soft

3. Métodos Off-Policy

3.1. Predicción Off-policy MC

3.2. Control Off-policy

4. Referencias



Silver, D. (2015). Lectures on Reinforcement Learning. <https://www.davidsilver.uk/teaching/>



Singh, S. P., & Sutton, R. S. (1996). Reinforcement learning with replacing eligibility traces. *Machine Learning*, 22(1-3), 123-158. <https://doi.org/10.1007/BF00114726>



Sutton, R., & Barto, A. (2018). *Reinforcement Learning, second edition: An Introduction*. MIT Press. <https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf>