

Extensiones de Machine Learning

PenTiDef

VÍCTOR SAURA MESEGUER

FRANCISCO JOSÉ CORTES DELGADO

GUILLERMO CARMONA MARTÍNEZ

Universidad de Murcia

Máster en Inteligencia Artificial

2025/2026



- ▶ 1. Introducción.
- ▶ 2. Estado del arte.
- ▶ 3. Amenazas contempladas.
- ▶ 4. Estructura y funcionamiento.
- ▶ 5. Resultados.
- ▶ 6. Conclusiones.

IDS + Machine Learning

- ▶ Detectan intrusiones por patrones de tráfico
- ▶ Necesitan datos diversos y abundantes
- ▶ Reentrenamiento continuo ante nuevas amenazas


El dilema de los datos

- ▶ Tráfico real = información sensible
- ▶ Privacidad y normativa bloquean compartirlo
- ▶ **FL**: entrenar sin mover los datos

¿Y si el propio FL clásico es el siguiente cuello de botella?

1. Introducción


Limitaciones del FL centralizado



- ▶ (1) SPOF: si cae el agregador, cae todo el sistema
- ▶ Servidor central = cuello de botella de comunicación
- ▶ (2) Heterogeneidad **non-IID** complica cualquier defensa

2. Estado del arte

Ataques sobre FL



- Privacidad: gradientes revelan clases, atributos y muestras
- Envenenamiento: *untargeted* (degrada) vs *targeted* (backdoor)

2. Estado del arte

Defensas existentes y sus límites

Privacidad

- ▶ **HE** (cifrado homomórfico): **coste enorme**
- ▶ **SMPC**: alto coste y sincronización
- ▶ **DP** diferencial: ligera y escalable
- ▶ Variantes: CDP / LDP / **DDP**

Robustez (espacio latente)

- ▶ **FLARE**: dataset auxiliar → **rompe privacidad**
- ▶ **FedCC**: PLR directo → **inestable non-IID**
- ▶ **Fed-LSAE**: AutoEncoder, pero PLR aún grande
- ▶ Todos asumen un **servidor central**

2. Estado del arte

Brecha que motiva PenTiDef

Ningún trabajo previo cubre simultáneamente:

- ▶ **Descentralización:** sin servidor confiable
- ▶ **Privacidad:** sin asumir confianza en el agregador
- ▶ **Robustez:** bajo distribuciones non-IID

$$PenTiDef = (\mathbf{Pen})_{ultimate} (\mathbf{T})_{rust} \\ pr(\mathbf{i})_{vacy\ preserving} (\mathbf{De})_{centralized} (\mathbf{F})_{ederated\ IDS}$$

3. Amenazas contempladas

Supuestos y Estrategias de Ataque

3.1 Configuración del Sistema

- ▶ Se asumen 20 colaboradores con una proporción de atacantes del 10%, 20% y 40%.
- ▶ El entrenamiento dura 10 rondas; los ataques se ejecutan desde la primera.

Ataques No Dirigidos

- ▶ **Label-flipping:** Inversión de etiquetas (benigno $\leftrightarrow$ ataque).
- ▶ **Weight Scaling:** Escalado de pesos locales mediante un factor $\lambda > 1$.
- ▶ **Untargeted-Krum/Med:** Manipulación para evadir algoritmos de agregación robustos.

Ataques Dirigidos

- ▶ **Backdoor:** Inyección de un activador (*trigger*) en los datos para causar comportamientos específicos inesperados.
- ▶ **GAN poisoning:** Uso de redes generativas para crear datos falsos que distorsionen el modelo global.

4.1.1 Componentes de la Arquitectura Estructura del Framework PenTiDef

- **Blockchain:** Red permissionada que actúa como orquestador descentralizado.
- **Chaincode:** Smart contracts que ejecutan la validación y filtrado.
- **PLR Extractor:** Obtiene las *Penultimate Layer Representations*.
- **AutoEncoder (AE):** Comprime las PLR en *Latent Space Representations* (LSR).
- **KMeans:** Agrupa los modelos según su similitud CKA para aislar atacantes.




Figure: Arquitectura PenTiDef

4.1.2 Principios de Funcionamiento

Algoritmo y Flujo de Trabajo

1. **Recuperación:** Los clientes obtienen el modelo global (GM) de la blockchain.
2. **Entrenamiento y Ruido:** Entrenamiento local seguido de perturbación por ruido DDP.
3. **Extracción PLR:** Los modelos enviados extraen sus representaciones de la penúltima capa.
4. **Reducción LSR:** El AutoEncoder comprime las PLR para mayor estabilidad ante datos no-IID.
5. **Similitud CKA:** Se calcula la similitud entre el GM y los modelos locales.
6. **Clustering:** KMeans divide los modelos en grupos mayoritarios (benignos) y minoritarios (atacantes).
7. **Agregación:** Solo los modelos benignos se combinan mediante el *Secure Aggregator*.
8. **Actualización:** El cliente más confiable propaga el nuevo GM a la red.

4.2 DDP con Nivel de Ruido Aleatorio

Privacidad Diferencial Distribuida

- **Mecanismo Gaussiano:** Se define como $\mathcal{M}(w) = w + \mathcal{N}(0, \sigma^2)$ para proteger los pesos locales.

Aleatoriedad de σ

Para evitar que los adversarios infieran patrones de ruido, PenTiDef selecciona σ aleatoriamente del intervalo $[0, 0.2]$ en cada ronda.

- **Beneficio:** Previene ataques de reconstrucción.
- **Transparencia:** Los niveles de ruido se registran en la blockchain para auditoría.

4.3 Integración de Blockchain

Coordinación en Federated Learning

- ▶ **Hyperledger Fabric:** Red permissionada (ni pública ni anónima) de 3 organizaciones y 6 nodos pares para mayor tolerancia a fallos.
- ▶ **Gestión de Identidad:** Uso de certificados digitales (ID_i, SK_i) para firmar transacciones y asegurar autenticidad.
- ▶ **Almacenamiento Híbrido:**
 - ▶ **On-chain:** Hashes de los modelos $h(w_i^t)$ y metadatos de auditoría.
 - ▶ **Off-chain:** Parámetros del modelo almacenados en **IPFS** para evitar cuellos de botella.
- ▶ **Transparencia:** Garantiza que solo actualizaciones verificadas entren en el estado de aprendizaje global.