

Extensiones de Machine Learning

PenTiDef

VÍCTOR SAURA MESEGUER

FRANCISCO JOSÉ CORTES DELGADO

GUILLERMO CARMONA MARTÍNEZ

Universidad de Murcia

Máster en Inteligencia Artificial

2025/2026



- ▶ 1. Introducción.
- ▶ 2. Estado del arte.
- ▶ 3. Amenazas contempladas.
- ▶ 4. Estructura y funcionamiento.
- ▶ 5. Resultados.
- ▶ 6. Conclusiones.

IDS + Machine Learning

- ▶ Detectan intrusiones por patrones de tráfico
- ▶ Necesitan datos diversos y abundantes
- ▶ Reentrenamiento continuo ante nuevas amenazas


El dilema de los datos

- ▶ Tráfico real = información sensible
- ▶ Privacidad y normativa bloquean compartirlo
- ▶ **FL**: entrenar sin mover los datos

¿Y si el propio FL clásico es el siguiente cuello de botella?

1. Introducción


Limitaciones del FL centralizado



- (1) SPOF: si cae el agregador, cae todo el sistema
- Servidor central = cuello de botella de comunicación
- (2) Heterogeneidad **non-IID** complica cualquier defensa

2. Estado del arte

Ataques sobre FL



- ▶ Privacidad: gradientes revelan clases, atributos y muestras
- ▶ Envenenamiento: *untargeted* (degrada) vs *targeted* (backdoor)

2. Estado del arte

Defensas existentes y sus límites

Privacidad

- ▶ **HE** (cifrado homomórfico): **coste enorme**
- ▶ **SMPC**: alto coste y sincronización
- ▶ **DP** diferencial: ligera y escalable
- ▶ Variantes: CDP / LDP / **DDP**

Robustez (espacio latente)

- ▶ **FLARE**: dataset auxiliar → **rompe privacidad**
- ▶ **FedCC**: PLR directo → **inestable non-IID**
- ▶ **Fed-LSAE**: AutoEncoder, pero PLR aún grande
- ▶ Todos asumen un **servidor central**

2. Estado del arte

Brecha que motiva PenTiDef

Ningún trabajo previo cubre simultáneamente:

- ▶ **Descentralización:** sin servidor confiable
- ▶ **Privacidad:** sin asumir confianza en el agregador
- ▶ **Robustez:** bajo distribuciones non-IID

$$PenTiDef = (\mathbf{Pen})_{ultimate} (\mathbf{T})_{rust} \\ pr(\mathbf{i})_{vacy\ preserving} (\mathbf{De})_{centralized} (\mathbf{F})_{ederated\ IDS}$$

3. Amenazas contempladas

Supuestos y Estrategias de Ataque

3.1 Configuración del Sistema

- ▶ Se asumen 20 colaboradores con una proporción de atacantes del 10%, 20% y 40%.
- ▶ El entrenamiento dura 10 rondas; los ataques se ejecutan desde la primera.

Ataques No Dirigidos

- ▶ **Label-flipping:** Inversión de etiquetas (benigno $\leftrightarrow$ ataque).
- ▶ **Weight Scaling:** Escalado de pesos locales mediante un factor $\lambda > 1$.
- ▶ **Untargeted-Krum/Med:** Manipulación para evadir algoritmos de agregación robustos.

Ataques Dirigidos

- ▶ **Backdoor:** Inyección de un activador (*trigger*) en los datos para causar comportamientos específicos inesperados.
- ▶ **GAN poisoning:** Uso de redes generativas para crear datos falsos que distorsionen el modelo global.

4.1.1 Componentes de la Arquitectura Estructura del Framework PenTiDef

- **Blockchain:** Red permissionada que actúa como orquestador descentralizado.
- **Chaincode:** Smart contracts que ejecutan la validación y filtrado.
- **PLR Extractor:** Obtiene las *Penultimate Layer Representations*.
- **AutoEncoder (AE):** Comprime las PLR en *Latent Space Representations* (LSR).
- **KMeans:** Agrupa los modelos según su similitud CKA para aislar atacantes.




Figure: Arquitectura PenTiDef

4.1.2 Principios de Funcionamiento

Algoritmo y Flujo de Trabajo

1. **Recuperación:** Los clientes obtienen el modelo global (GM) de la blockchain.
2. **Entrenamiento y Ruido:** Entrenamiento local seguido de perturbación por ruido DDP.
3. **Extracción PLR:** Los modelos enviados extraen sus representaciones de la penúltima capa.
4. **Reducción LSR:** El AutoEncoder comprime las PLR para mayor estabilidad ante datos no-IID.
5. **Similitud CKA:** Se calcula la similitud entre el GM y los modelos locales.
6. **Clustering:** KMeans divide los modelos en grupos mayoritarios (benignos) y minoritarios (atacantes).
7. **Agregación:** Solo los modelos benignos se combinan mediante el *Secure Aggregator*.
8. **Actualización:** El cliente más confiable propaga el nuevo GM a la red.

4.2 DDP con Nivel de Ruido Aleatorio

Privacidad Diferencial Distribuida

- **Mecanismo Gaussiano:** Se define como $\mathcal{M}(w) = w + \mathcal{N}(0, \sigma^2)$ para proteger los pesos locales.

Aleatoriedad de σ

Para evitar que los adversarios infieran patrones de ruido, PenTiDef selecciona σ aleatoriamente del intervalo $[0, 0.2]$ en cada ronda.

- **Beneficio:** Previene ataques de reconstrucción.
- **Transparencia:** Los niveles de ruido se registran en la blockchain para auditoría.

4.3 Integración de Blockchain

Coordinación en Federated Learning

- ▶ **Hyperledger Fabric:** Red permissionada (ni pública ni anónima) de 3 organizaciones y 6 nodos pares para mayor tolerancia a fallos.
- ▶ **Gestión de Identidad:** Uso de certificados digitales (ID_i, SK_i) para firmar transacciones y asegurar autenticidad.
- ▶ **Almacenamiento Híbrido:**
 - ▶ **On-chain:** Hashes de los modelos $h(w_i^t)$ y metadatos de auditoría.
 - ▶ **Off-chain:** Parámetros del modelo almacenados en **IPFS** para evitar cuellos de botella.
- ▶ **Transparencia:** Garantiza que solo actualizaciones verificadas entren en el estado de aprendizaje global.

Efectividad del framework

- ▶ **RQ1:** ¿Cómo afecta DDP al rendimiento del modelo?
- ▶ **RQ3:** ¿PenTiDef frente a FLARE y FedCC?
- ▶ **RQ4:** ¿Detecta ataques *targeted* y *untargeted*?

Robustez y escalabilidad

- ▶ **RQ2:** ¿Comportamiento bajo IID vs non-IID?
- ▶ **RQ5:** ¿Coste computacional y tiempo de entrenamiento?
- ▶ **RQ6:** ¿Estabilidad cambiando la arquitectura DL?
- ▶ **RQ7:** ¿Rendimiento de la capa blockchain?

Siete preguntas $\Rightarrow$ cuatro escenarios experimentales.

5. Resultados

Escenarios experimentales

#	Escenario	Foco	RQs
1	Impacto de DDP	PenTiDef con y sin ruido DDP	RQ1
2	Comparativa de defensas	vs. FLARE y FedCC, IID y non-IID	RQ2–RQ5
3	Cross-architecture	CNN vs. SqueezeNet	RQ5, RQ6
4	Capa blockchain	Latencia y <i>throughput</i> (Fabric)	RQ7

- Cada escenario responde a una o varias RQs.
- Combinan **detección**, **coste** y **coordinación**.

5. Resultados

Configuración experimental

Entorno

- ▶ AMD Ryzen 7 6800HS + 16 GB RAM
- ▶ Hyperledger Fabric (3 orgs, 6 nodos)
- ▶ IPFS para *off-chain storage*
- ▶ 20 clientes; atacantes: 10 / 20 / 40%
- ▶ 10 rondas FL, ataques desde la 1ª

Modelo IDS

- ▶ CNN 1D (11 capas ocultas), Adam + ReLU
- ▶ Batch 1024, 5 épocas locales
- ▶ SqueezeNet como *backbone* alternativo

Datasets:

- ▶ **CIC-IDS2018:** 71 *features*, 42.6% benigno / 57.4% ataque.
- ▶ **Edge-IIoTSet:** 95 *features*, 71.4% benigno / 28.6% ataque.
- ▶ 70% *train* / 30% *test*; particiones IID y non-IID.

Clasificación binaria

- ▶ **Accuracy:** clasificaciones correctas totales.
- ▶ **Precision:** fiabilidad de la detección positiva.
- ▶ **Recall:** cobertura de ataques reales.
- ▶ **F1-Score:** media armónica (balancea *precision* y *recall*).


Filtrado de clientes

- ▶ **CKA Score:** similitud entre espacios latentes.
 - ▶ CKA alto $\Rightarrow$ benigno.
 - ▶ CKA bajo $\Rightarrow$ candidato a envenenamiento.
- ▶ **Tiempo medio** como *proxy* de coste.
- ▶ **Latencia / TPS** para la capa blockchain.

5.1 Resultado 1

Impacto de DDP sobre el rendimiento (RQ1)

- ▶ **Sin DDP:** convergencia rápida, ~ 0.98 desde la ronda 3.
- ▶ **Con DDP** ($\sigma \in [0, 0.2]$): arranque más lento por el ruido, estabiliza hacia la ronda 10.
- ▶ Diferencia final en Accuracy, Precision, Recall y F1: ≈ 0.01 .



Conclusión

DDP añade **privacidad por diseño** con un coste prácticamente despreciable en utilidad.

5.2 Resultado 2


Ataques no dirigidos (IID, F1-Score)

Dataset	Ataque	Adversarios 20%			Adversarios 40%		
		Flare	FedCC	PenTiDef	Flare	FedCC	PenTiDef
CIC-IDS2018	Label-flipping	0.93	0.95	0.96	0.92	0.95	0.96
	Weight-Scaling	0.97	0.95	0.96	0.92	0.95	0.96
	Un-Krum	0.95	0.96	0.97	0.96	0.88	0.93
	Un-Med	0.95	0.93	0.98	0.91	0.92	0.97
Edge-IIoTSet	Label-flipping	0.96	0.96	0.97	0.88	0.88	0.92
	Weight-Scaling	0.95	0.97	0.95	0.91	0.88	0.95
	Un-Krum	0.98	0.91	0.96	0.91	0.87	0.93
	Un-Med	0.88	0.93	0.99	0.88	0.88	0.95

- PenTiDef gana o empatía en **la mayoría** de configuraciones.
- A mayor % de atacantes, mayor ventaja $\Rightarrow$ las defensas rivales se degradan más rápido.

5.2 Resultado 2

Discriminación benigno / malicioso (CKA, non-IID)



- ▶ **PenTiDef**: $CKA \approx 0.85$ (benignos) $\rightarrow \approx 0.45$ (atacantes).
- ▶ **FedCC**: ≈ 0.80 en ambos grupos $\Rightarrow$ no discrimina.
- ▶ El AutoEncoder + LSR hace la señal **estable** en non-IID.

¿Por qué PenTiDef discrimina mejor?

FedCC: PLR $\rightarrow$ CKA $\rightarrow$ clustering

PenTiDef: PLR $\rightarrow$ AE $\rightarrow$ LSR $\rightarrow$ CKA $\rightarrow$ clustering

El paso **LSR** limpia ruido, estabiliza representaciones y mejora la separación.

5.2 Resultado 2

Peor caso: 40% adversarios (F1-Score)

Datos	Ataque	Dataset	Flare	FedCC	PenTiDef
IID	GAN-SL	CIC-IDS2018	0.90	0.93	0.94
	GAN-ML	CIC-IDS2018	0.93	0.96	0.97
	GAN-Con	Edge-IloTSet	0.93	0.92	0.94
	Backdoor	Edge-IloTSet	0.94	0.94	0.95
non-IID	Un-Med	CIC-IDS2018	0.87	0.88	0.95
	Un-Krum	CIC-IDS2018	0.92	0.84	0.89
	Label-flipping	Edge-IloTSet	0.84	0.85	0.88
	Un-Med	Edge-IloTSet	0.84	0.84	0.91

- ▶ Con **4 de cada 10 clientes maliciosos**, PenTiDef mantiene $F1 \geq 0.88$ en casi todos los casos.
- ▶ La caída típica de FLARE/FedCC al pasar a non-IID es de $\sim 0.05\text{--}0.10$; PenTiDef resiste.

5.2 Resultado 2

Eficiencia: tiempo de entrenamiento

Dataset	Modelo	Tiempo
CIC-IDS2018	FLARE	3 907 s ($\sim 1\text{h } 06\text{m}$)
	FedCC	2 460 s ($\sim 41\text{m}$)
	PenTiDef	1 988 s ($\sim 33\text{m}$)
Edge-IIoTSet	FLARE	4 395 s ($\sim 1\text{h } 15\text{m}$)
	FedCC	2 825 s ($\sim 47\text{m}$)
	PenTiDef	1 869 s ($\sim 31\text{m}$)

¿Por qué es más rápido?

- ▶ FLARE requiere un *dataset auxiliar* para comparar PLR.
- ▶ FedCC compara PLR crudas $\Rightarrow$ vector de gran dimensión.
- ▶ PenTiDef comprime PLR $\rightarrow$ **LSR** (AutoEncoder) antes de CKA.

$\sim 2\times$ más rápido que FLARE
y sin comprometer detección.

5.3 Resultado 3

Robustez entre arquitecturas (RQ5, RQ6)

Mismo framework, distinto *backbone*

- ▶ CNN $\leftrightarrow$ SqueezeNet sin rediseñar el filtrado.
- ▶ Los 4 ataques evaluados, IID y non-IID.

Hallazgos

- ▶ CNN $\gtrsim$ SqueezeNet en la mayoría de escenarios.
- ▶ Ambos mantienen $F1 \geq 0.89$ con 40% de atacantes.
- ▶ La defensa opera sobre la **penúltima capa**: es *model-agnostic*.

Dataset	Ataque	CNN	SqueezeNet
<i>IID · 40% adversarios</i>			
CIC-IDS2018	Label-flipping	0.94	0.96
CIC-IDS2018	Weight-Scaling	0.96	0.97
Edge-IIoTSet	Un-Krum	0.89	0.90
<i>non-IID · 40% adversarios</i>			
CIC-IDS2018	Label-flipping	0.93	0.95
Edge-IIoTSet	Backdoor	0.95	0.95

5.4 Resultado 4

Capa blockchain bajo carga (RQ7)

Operación	Rate env.	Lat. media	Throughput
CreateModel	5 TPS	0.21 s	28.0 TPS
CreateModel	20 TPS	0.12 s	84.5 TPS
QueryAllModels	20 TPS	0.17 s	82.1 TPS
QueryByModelIndex	20 TPS	0.09 s	177.5 TPS
QueryByBenignClientID	20 TPS	0.31 s	47.4 TPS

- ▶ **0 transacciones fallidas** en 5 000 y 10 000 pruebas.
- ▶ Latencia media < 0.35 s incluso con 10 000 transacciones.
- ▶ Hyperledger Fabric soporta la coordinación **sin cuello de botella**.

6. Conclusiones

Discusión: logros y limitaciones

Logros

- ▶ Defensa robusta frente a ataques *targeted* y *untargeted*.
- ▶ Estable bajo non-IID y hasta un **40%** de atacantes.
- ▶ Sin dataset auxiliar ni conocimiento previo de adversarios.
- ▶ Coordinación **sin servidor central** vía blockchain.
- ▶ Menor tiempo de entrenamiento que FLARE y FedCC.

Limitaciones

- ▶ Sólo clasificación **binaria** (benigno / ataque).
- ▶ No evaluado frente a adversarios adaptativos avanzados (*model inversion*, *backdoors* semánticos).
- ▶ Ruido DDP aleatorio → posible vector *free-rider*.
- ▶ Coste de la blockchain no analizado a gran escala.

Contribución

PenTiDef integra **DDP**, **LSR + CKA** y **blockchain** en un framework único de IDS federado descentralizado, superando a FLARE y FedCC en precisión, robustez y eficiencia.

Trabajo futuro

- ▶ Clasificación **multiclase** de ataques.
- ▶ Ajuste **adaptativo** de σ en DDP.
- ▶ Detectores contra *free-riders* y GAN avanzadas.
- ▶ Explicabilidad (XAI) del filtrado.

Aplicabilidad

- ▶ IoMT y salud conectada.
- ▶ Edge computing.
- ▶ Infraestructuras críticas distribuidas.

Donde privacidad + descentralización + tiempo real son obligatorias.

¿Preguntas?

PenTiDef = **P**enultimate **T**rust
privacy preserving **D**ecentralized **F**ederated IDS

Víctor Saura Meseguer · Francisco José Cortés Delgado · Guillermo Carmona Martínez

Máster en Inteligencia Artificial — Universidad de Murcia