

Aprendizaje por Refuerzo

Bandido Multibrazo

LUIS DANIEL HERNÁNDEZ MOLINERO

CIENCIA DE LA COMPUTACIÓN E INTELIGENCIA ARTIFICIAL

DEPT. INGENIERÍA DE LA INFORMACIÓN Y LAS COMUNICACIONES

Universidad de Murcia

Máster en Inteligencia Artificial

2025 / 2026



1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Retroalimentación Evaluativa

- ▶ Se basa en la acción tomada, evaluando qué tan buena fue.
- ▶ No dice si la acción fue la mejor posible.
- ▶ Es típica en el aprendizaje por refuerzo

Retroalimentación Instructiva

- ▶ Indica la acción correcta sin depender de la acción tomada.
- ▶ Es típica en el aprendizaje supervisado.

Estos dos tipos de retroalimentación son bastante distintos, pero pueden combinarse.

- ▶ El **problema del bandido multi-brazo** es una versión simplificada de un **entorno no asociativo**.
Un agente debe elegir repetidamente entre diferentes opciones (o "brazos") sin conocer las recompensas.
- ▶ Este problema introduce **métodos básicos de aprendizaje** que se extenderán para el RL completo.
- ▶ Hay que encontrar el equilibrio entre **exploración** y **explotación**.
- ▶ El siguiente paso en el aprendizaje por refuerzo es considerar **entornos asociativos**.



Desarrollo

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Planteamiento del Problema

Planteamiento del Problema

Para cada paso $t = 1, 2, \dots, T$

Tienes que elegir entre k opciones diferentes (o acciones)

Al elegir $a_t \in A$, recibes r_t



i ¿Por qué bandido k -brazos?

- ▶ Un bandido es una máquina tragamonedas.
- ▶ Un bandido de k -brazos es seleccionar la mejor entre k -máquinas.


Formalización. (Robbins, 1952)

- ▶ Tenemos un conjunto A de K acciones (los brazos). $A = \{a_1, a_2, \dots, a_k\}$
- ▶ Lo que sucede en cada paso de tiempo, $t = 1, 2, \dots, T$ es que:
 - ▶ Elegiremos una acción $a_t \in A$
 - ▶ Obtendremos una recompensa a partir de una distribución desconocida $r_t \sim Pr(r|a_t)$
- ▶ El objetivo, para cualquier algoritmo bandido, es maximizar la recompensa acumulada: $\sum_t r_t$

Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Ejemplos: A/B testing



1. **Marketing Digital:** anuncios online, landing pages, e-mails, ...
2. **Diseño Web (Experiencia de Usuario):** interfaz de usuario (UI), flujos de usuarios, tiempos de carga, ...
3. **E-commerce:** checkout, productos recomendados, descuentos y promociones, ...
4. **Desarrollo de Producto:** características del producto, modelos de precios, interacciones, ...
5. **Redes Sociales:** contenidos, anuncios patrocinados, ...
6. **Publicidad Digital:** CTR (Click-through rate), conversión, ...
7. **Medios de Comunicación y Editoriales:** títulos de artículos, formatos de contenido, ...
8. **App. Móviles:** pantallas de bienvenida, interfaz en móviles, ...
9. **Juegos en Línea:** monetización, características del juego, ...
10. **Medicina y Ciencias de la Salud:** ensayos clínicos, ...
11. etc

T -veces seleccionamos entre K -acciones y obtenemos una recompensa $r_t \sim Pr(r|a_t)$. Objetivo: $\max \sum_t r_t$

Ejemplos: Ensayos clínicos

Administración de Fármacos



CAN YOU BEAT THE BANDIT ALGORITHMS?

CONFIGURATION

Drugs: 4 Patients: 40

MEDICAL TESTING

Drug 1 Drug 2 Drug 3 Drug 4

TRIAL RESULTS

Trial complete, please see plot below or start again.

Timestep: 39, Drug: 3, Patient: Die

Timestep: 38, Drug: 2, Patient: Live

Timestep: 37, Drug: 1, Patient: Die

Timestep: 36, Drug: 4, Patient: Die

<https://iosband.github.io/2015/07/28/Beat-the-bandit.html>

T -veces seleccionamos entre K -acciones y obtenemos una recompensa $r_t \sim Pr(r|a_t)$. Objetivo: $\max \sum_t r_t$



Desarrollo

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

- ▶ **Round-robin:** método que distribuye equitativamente o de forma cíclica recursos o tareas entre varios participantes, procesos o equipos.
- ▶ Adaptación al problema del bandido multibrazo:

Algoritmo 1 Algoritmo Round-Robin para el Problema del Bandido Multibrazo

Entrada: Número de acciones T , número de opciones (brazos) K

- 1: **Inicialización:** Recompensas acumuladas $R_k \leftarrow 0$ para cada opción $k = 1, 2, \dots, K$
- 2: Inicializar el contador de elecciones $N_k \leftarrow 0$ para cada opción $k = 1, 2, \dots, K$
- 3: Crear una cola circular de opciones $\{1, 2, \dots, K\}$
- 4: **for** $t = 1$ **hasta** T **do**
- 5: Seleccionar la opción $k = ((t - 1) \bmod K) + 1$ (Round-Robin)
- 6: Realizar la acción k y observar la recompensa r_k
- 7: Actualizar el valor de recompensa acumulada: $R_k \leftarrow R_k + r_k$
- 8: Actualizar el contador de elecciones: $N_k \leftarrow N_k + 1$
- 9: **end for**
- 10: **return** Recompensas acumuladas R_k y contadores N_k para cada opción k

-
- ▶ No es eficiente.




Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. **Métodos acción-valor**
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

► Valor de la acción a :

$$q(a) = \mathbb{E}[R_t | A_t = a].$$

- A_t : la acción seleccionada en el paso de tiempo t ,
- R_t : la recompensa correspondiente en el paso t ,
- $\mathbb{E}$: el **operador de esperanza o valor esperado**.



- No conocemos las distribuciones de probabilidad: es necesario estimar $q(a)$.
- **Métodos de Acción-Valor:** Los que usan estimaciones $Q_t(a)$ para tomar decisiones.
- **Valor estimado de la acción a según el método de promedio de muestras:**

$$Q_t(a) = \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{I}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{I}_{A_i=a}} \quad (1)$$



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

- **Algoritmo voraz:** Elegir aquella acción que tenga asociada una mayor recompensa.

$$A_t = \arg_a \max Q_t(a) \quad (2)$$

Algoritmo 2 Algoritmo Greedy para el Problema del Bandido Multibrazo

Entrada: Número de acciones T , número de opciones (brazos) K

- 1: **Inicialización:** Recompensas acumuladas $R_k \leftarrow 0$ y contador de elecciones $N_k \leftarrow 0$ para cada opción $k = 1, 2, \dots, K$
 - 2: Seleccionar cada opción k **una vez** para inicializar la recompensa (**necesario**)
 - 3: **for** $t = K + 1$ **hasta** T **do**
 - 4: Seleccionar la opción k que maximiza $\frac{R_k}{N_k}$ (la opción con mayor recompensa promedio)
 - 5: Realizar la acción k y observar la recompensa r_k
 - 6: Actualizar el valor de recompensa acumulada: $R_k \leftarrow R_k + r_k$
 - 7: Actualizar el contador de elecciones: $N_k \leftarrow N_k + 1$
 - 8: **end for**
 - 9: **return** Recompensas acumuladas R_k y contadores N_k para cada opción k
-

- **Problema:** solo realiza explotaciones y no hace ningún intento de explorar.



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Implementación Incremental

- ▶ Los métodos de acción-valor estiman los valores de las acciones como promedios de las recompensas.
- ▶ ¿Se puede calcular el promedio de forma más eficiente el siguiente cálculo?

$$\begin{aligned}Q_{n+1} &= \frac{1}{n} \sum_{i=1}^n R_i \text{ (para 1 acción)} \\&= \frac{1}{n} \left(R_n + \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} \left(R_n + (n-1) \frac{1}{n-1} \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} (R_n + (n-1)Q_n) \\&= \frac{1}{n} (R_n + nQ_n - Q_n) \\&= Q_n + \frac{1}{n} (R_n - Q_n)\end{aligned}\tag{3}$$

- ▶ $\text{NuevoEstimado} = \text{ViejoEstimado} + \text{Tamaño del Paso} \cdot (\text{Objetivo} - \text{ViejoEstimado})$.

Implementación incremental del algoritmo greedy

Algorithm 3 Algoritmo Greedy Incremental para el Problema del Bandido Multibrazo

Entrada: Número de acciones T , número de opciones (brazos) K

- 1: **Inicialización:** Promedio de recompensa estimado $Q_k \leftarrow 0$ y contador de elecciones $N_k \leftarrow 0$ para cada opción $k = 1, 2, \dots, K$
- 2: Seleccionar cada opción k **una vez** para inicializar el promedio de recompensa (**necesario**)
- 3: **for** $t = K + 1$ **hasta** T **do**
- 4: Seleccionar la opción k que maximiza Q_k (la opción con mayor recompensa promedio estimada)
- 5: Realizar la acción k y observar la recompensa r_k
- 6: Actualizar el promedio de recompensa estimado para la opción seleccionada:

$$Q_k \leftarrow Q_k + \frac{1}{N_k + 1}(r_k - Q_k)$$

- 7: Actualizar el contador de elecciones: $N_k \leftarrow N_k + 1$
 - 8: **end for**
 - 9: **return** Promedios de recompensa Q_k y contadores N_k para cada opción k
-



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. **Añadiendo Exploración**
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. **Añadiendo Exploración**
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Algoritmo ϵ -greedy

- Ser codicioso (explotar), pero no siempre (explorar) con una probabilidad ϵ .

Algorithm 4 Algoritmo ϵ -Greedy para el Problema del Bandido Multibrazo

Entrada: Número de acciones T , número de opciones (brazos) K , parámetro de exploración ϵ

- 1: **Inicialización:** Recompensas acumuladas $R_k \leftarrow 0$ y contador de elecciones $N_k \leftarrow 0$ para cada opción $k = 1, 2, \dots, K$
 - 2: Seleccionar cada opción k una vez para inicializar la recompensa (**opcional**)
 - 3: **for** $t = K + 1$ **hasta** T **do**
 - 4: Generar un número aleatorio p entre 0 y 1
 - 5: **if** $p < \epsilon$ **then**
 - 6: **Exploración:** Seleccionar una opción k aleatoria entre 1 y K
 - 7: **else**
 - 8: **Explotación:** Seleccionar la opción k que maximiza $\frac{R_k}{N_k}$ (la opción con mayor recompensa promedio)
 - 9: **end if**
 - 10: Realizar la acción k y observar la recompensa r_k
 - 11: Actualizar el valor de recompensa acumulada: $R_k \leftarrow R_k + r_k$
 - 12: Actualizar el contador de elecciones: $N_k \leftarrow N_k + 1$
 - 13: **end for**
 - 14: **return** Recompensas acumuladas R_k y contadores N_k para cada opción k
-

- $\lim_{t \rightarrow \infty} Q_t(a) = q(a)$




- **Ejercicio.** Para el caso de dos acciones y $\epsilon = 0,5$, ¿cuál es la probabilidad de que se seleccione la acción codiciosa?

Implementación incremental de ϵ -greedy

Algorithm 5 Algoritmo ϵ -Greedy Incremental para el Problema del Bandido Multibrazo

```
1: Inicialización:  
2: for  $a = 1$  to  $k$  do  
3:    $Q(a) \leftarrow 0$   
4:    $N(a) \leftarrow 0$   
5: end for  
6: while True do  
7:   Seleccionar una acción  $A$ :  
8:    $A \leftarrow \begin{cases} \arg \max_a Q(a) & \text{con probabilidad } 1 - \epsilon \\ \text{una acción aleatoria} & \text{con probabilidad } \epsilon \end{cases}$  (rompiendo aleatoriamente)  
9:    $R \leftarrow \text{bandit}(A)$  (Obtener la recompensa de la acción seleccionada)  
10:   $N(A) \leftarrow N(A) + 1$  (Actualizar el contador de la acción)  
11:   $Q(A) \leftarrow Q(A) + \frac{1}{N(A)} \cdot (R - Q(A))$  (Actualizar el valor estimado)  
12: end while
```

Comparativa ϵ -greedy



Figuras de Sutton y Barto, 2018



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Método de Valores Iniciales Optimistas

- ▶ Constan de dos pasos generales:
 1. Inicializar las estimaciones $Q_1(a)$ a un valor extremadamente optimista.
 2. Aplicar un algoritmo voraz.
- ▶ Se espera que haya una gran exploración al principio y después se centre en la explotación.
- ▶ Algoritmo Voraz Optimista. Ejemplos:
 - ▶ Fármacos: $Q_1(a) = 1$
 - ▶ 10-brazos: $Q_1(a) = 5$

Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. **Añadiendo Exploración**
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Algoritmo ϵ -decaimiento

- A medida que el agente acumula experiencia, el objetivo es hacer una mayor explotación de las mejores acciones conocidas y reducir la exploración con probabilidad ϵ .

Algorithm 6 ϵ -decaimiento para selección de acciones

Entrada: N^a de acciones K , N^a de pasos T , valor inicial de exploración ϵ_0 , tasa de decaimiento λ , valor mínimo de exploración $\epsilon_{\min}$.

- 1: **Inicialización:** Recompensas acumuladas $R_k \leftarrow 0$ y contador de elecciones $N_k \leftarrow 0$ para cada acción $k = 1, 2, \dots, K$
 - 2: Generar cada opción k una vez para inicializar la recompensa.
 - 3: **for** $t = 1$ **hasta** T **do**
 - 4: Calcular $\epsilon_t = \max(\epsilon_{\min}, f(t, \epsilon_0, \lambda))$.
 - 5: **Con probabilidad** ϵ_t :
 - 6: Seleccionar una acción k al azar de entre las K acciones (exploración)
 - 7: **Con probabilidad** $1 - \epsilon_t$:
 - 8: Seleccionar la acción $k = \arg \max \frac{R_k}{N_k}$ (explotación)
 - 9: Realizar la acción k y observar la recompensa r_k
 - 10: Actualizar la recompensa acumulada: $R_k \leftarrow R_k + r_k$
 - 11: Actualizar el contador de elecciones: $N_k \leftarrow N_k + 1$
 - 12: **end for**
 - 13: **Salida:** Recompensas acumuladas R_k y contadores N_k para cada acción k
-

► Decaimiento Lineal:

$$f(t, \epsilon_0, \lambda) = \epsilon_0 - t \cdot \lambda$$


► Decaimiento Exponencial:

$$f(t, \epsilon_0, \lambda) = \epsilon_0 \cdot e^{-\lambda t}$$

► Decaimiento Inversamente Proporcional:

$$f(t, \epsilon_0, \lambda) = \frac{\epsilon_0}{1 + \lambda t}$$

Comparación de Funciones de Decaimiento de ϵ



- $\epsilon_0 = 1,0$

- $\lambda = 0,01$

Con probabilidad $\epsilon_t = \max(\epsilon_{\min}, f(t, \epsilon_0, \lambda))$ tomamos una acción al azar.



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. **Métodos índice**
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

¿Cómo medir la eficiencia de un algoritmo?

- ▶ Para comparar algoritmos entre sí ¿es mejor el que haya obtenido más recompensa?
- ▶ Arrepentimiento: $R_T = \sum_{t=1}^T (q^* - r_t) = q^* T - \sum_{t=1}^T r_t$ con $q^* = \max_{a \in A} q(a)$

Algorithm 7 Cálculo de arrepentimiento

Entrada: N^o de pasos T , N^o de brazos $arms$, $reward \leftarrow 0$,
recompensas verdaderas $q(a) = rand(0, max)$

- 1: **for** $t = 1$ hasta T **do**
- 2: $arm \leftarrow bandit(t)$
- 3: $r \leftarrow random.normal(q(arm), 1, 0)$ # Supuesto que es $N(\mu, 1)$
- 4: $reward \leftarrow reward + r$
- 5: **end for**
- 6: $QMAX = \max_{a \in arms} q(a)$
- 7: $regret \leftarrow QMAX * T - reward$

Salida: $regret$

- ▶ Pero la expresión a estudiar es:

Arrepentimiento (esperado)

$$\mathbb{E}[R_T] = \mathbb{E}\left[\sum_{i=1}^T (q^* - r_t)\right] = q^* T - \sum_{t=1}^T \mathbb{E}(r_t)$$

Arrepentimiento (Esperado)

► Un desarrollo conveniente (Bonald, 2017):

$$\begin{aligned}
 L_T = \mathbb{E}[R_T] &= \mathbb{E}\left[\sum_{i=1}^T (q^* - r_t)\right] &= T \mathbb{E}[r|a^*] - \sum_{t=1}^T \mathbb{E}[r|a_t] \\
 &= Tq^* - \sum_{t=1}^T \mathbb{E}[q(a_t)] &= Tq^* - \sum_{t=1}^T \sum_{a \in A} \mathbb{E}[q(a) \cdot \mathbb{I}_{a_t=a}] \\
 &= Tq^* - \sum_{a \in A} q(a) \sum_{t=1}^T \mathbb{E}[\mathbb{I}_{a_t=a}] &= Tq^* - \sum_{a \in A} q(a) \mathbb{E}\left[\sum_{t=1}^T \mathbb{I}_{a_t=a}\right] \\
 &= Tq^* - \sum_{a \in A} q(a) \mathbb{E}[N_T(a)] &= \sum_{a \in A} (q^* - q(a)) \mathbb{E}[N_T(a)]
 \end{aligned}$$

►
$$\mathbb{E}[N_T(a)] = \sum_{t=1}^T \mathbb{E}[\mathbb{I}_{a_t=a}] = \sum_{i=1}^T [1 \cdot P(a_t = a) + 0 \cdot P(a_t \neq a)] = \sum_{t=1}^T P(a_t = a) = \sum_{t=1}^T P(a) = T \cdot P(a)$$

Arrepentimiento

- Lai y Robbins, 1985 demuestra que bajo ciertas condiciones se cumple

$$\liminf_{T \rightarrow \infty} \frac{\sum_{i: \mu_i < \mu^*} (\mu^* - \mu_i) E[n_i]}{\ln(T)} \geq \sum_{i: \mu_i < \mu^*} \frac{\mu^* - \mu_i}{I(\mu_i, \mu^*)} = Cte$$

- El numerador es L_T : $q^* = \mu^*$, $q(a_i) = \mu_i$, $E[n_i] = \mathbb{E}[N_T(a_i)]$.
- Nota: Si $a_n = (-1)^n + \frac{1}{n}$, entonces $\lim_{n \rightarrow \infty} a_n$ no existe, pero $\liminf_{n \rightarrow \infty} a_n = -1$.
- Consecuencia: $L_t \geq Cte \cdot \ln(T)$

- **Requisito:** $\mathbb{E}[n_i] \geq \frac{\ln(T)}{I(\mu_i, \mu^*)}$

- Divergencia de Kullback-Leibler: $I(\mu_j, \mu^*) = \int_{-\infty}^{+\infty} \log \left(\frac{p_i(x)}{p^*(x)} \right) p_j(x) dx$
 - Divergencia de Kullback-Leibler de j respecto de la óptima.
 - No es conmutativa.
- Se espera que el número de veces que el brazo i haya sido elegido $\mathbb{E}[n_i]$ sea superior a cierto valor.



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

- ▶ ϵ -greedy puede explorar seleccionando una acción mala. Entonces, podríamos usar algún tipo de medida que indique un equilibrio entre el valor conocido y la incertidumbre.
- ▶ Agrawal, 1995 introdujo una clase genérica de políticas de índice denominadas límites superiores de confianza (upper confidence bounds, UCB), basado en Lai y Robbins, 1985.
- ▶ El método de **límites superiores de confianza** (UCB) mide el potencial de cada brazo con un índice para cada política (brazo/acción) que está formado por la suma de dos términos.

$$ucb(a) = Q(a) + u(a)$$

- ▶ Término de explotación, $Q(a)$
- ▶ Término de exploración, $u(a)$ (límite superior)
 - Una medida de la incertidumbre asociada con la estimación de la recompensa promedio del brazo a .
 - Debe ser más pequeño conforme aumenta el número de veces que se selecciona la acción a .
- ▶ Si $q(a) \in [Q(a) - u(a), Q(a) + u(a)]$, entonces $q(a) \leq Q(a) + u(a)$
- ▶ Siempre selecciona la acción más codiciosa para maximizar el límite superior de confianza

$$a_t = \arg \max_{a \in A} ucb(a)$$

Método UCB1

► Existen varias versiones del algoritmo Upper Confidence Bound (UCB).

► Peter Auer et al., 2002: UCB1

- Es la primera versión concreta y práctica del concepto de UCB
- La designación "1" por ser la primera y distinguirla de otras variantes.

► **Desigualdad de Hoeffding:** $Pr(|\bar{X} - \mu| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$

- $\bar{X}$ es la media de los valores $\mapsto Q_t(a)$ estimación del valor de la acción a en el tiempo t .
- μ es la media de la distribución $\mapsto q(a)$ valor de la acción.
- ε es el valor máximo para el que queremos medir la probabilidad $\mapsto u(a)$ limite superior de confianza
- n es el número de muestras $\mapsto N_t(a)$ número de veces que la acción a ha sido seleccionada antes de t .

► Definiendo $\varepsilon = \sqrt{\frac{1}{2n} \ln \frac{2}{\alpha}}$, obtenemos $Pr(|\bar{X} - \mu| \geq \varepsilon) \leq 2e^{-2n\left(\sqrt{\frac{1}{2n} \ln \frac{2}{\alpha}}\right)^2} = e^{-\ln \frac{2}{\alpha}} = \frac{2}{\alpha}$

► UCB1 establece $\frac{2}{\alpha} = t^{-4}$, con t el número total de acciones.

$$u(a) = \varepsilon = \sqrt{\frac{1}{2N_t(a)} \ln \frac{2}{\alpha}} = \sqrt{\frac{1}{2N_t(a)} \ln t^4} = \sqrt{\frac{2 \ln t}{N_t(a)}}$$

$$A_t = \arg \max_{a \in A} Q_t(a) + \sqrt{\frac{2 \ln t}{N_t(a)}}$$

Valor $UCB1(a) = Q(a) + c \times \sqrt{\frac{\ln t}{N(a)}}$

- c : parámetro de ajuste que controla el grado de exploración (usualmente se toma $c = 1$).

Método UCB2

► En el mismo artículo, Peter Auer et al., 2002 propone UCB2

► Valor
$$UCB2(a) = Q(a) + \sqrt{\frac{(1+\alpha) \ln\left(\frac{e \cdot t}{\tau(k_a)}\right)}{2\tau(k_a)}}$$

- $0 < \alpha < 1$: parámetro de ajuste para el balance entre exploración y explotación.
- k_a : número de épocas de la acción a .
- $\tau(k_a) = \lceil (1 + \alpha)^{k_a} \rceil$: determina el número de veces que la acción a será seleccionada en un época.

Algorithm 8 Algoritmo UCB2

- 1: **Inicialización de valores:** $0 < \alpha < 1$, $t \leftarrow 0$, $N(a) \leftarrow 0$, $Q(a) \leftarrow 0$, $k_a \leftarrow 0$
 - 2: **Inicialización de recompensas:** Selecciona cada acción una vez, actualizando t , $N(a) \leftarrow 1$, $Q(a)$
 - 3: **while** el criterio de parada no se cumpla ($t < T$) **do**
 - 4: **Seleccionar la Acción con el Índice Máximo:** $a \leftarrow \arg \max_{a'} UCB2(a')$
 - 5: **Ejecuta la acción a el número de veces que indique su bloque de tiempo**

$$\lceil \tau(k_a + 1) - \tau(k_a) \rceil$$

Actualizando $t \leftarrow t + 1$, $N(a) \leftarrow N(a) + 1$ y el promedio de recompensas $Q(a)$.
 - 6: Actualizar $k_a \leftarrow k_a + 1$
 - 7: **end while**
-

Variantes UCB1-Tuned

► **UCB1-Tuned** Valor
$$\text{UCB1-Tuned}(a) = Q(a) + \sqrt{\frac{\ln t}{N(a)}} \cdot \min \left(\frac{1}{4}, V(a) + \sqrt{\frac{2 \ln t}{N(a)}} \right)$$

- $V(a)$: estimación de la varianza empírica de las recompensas para la acción a .
 - La varianza empírica de las recompensas se calcula como: $V(a) = \frac{1}{N(a)} \sum_{i=1}^{N(a)} (r_i - Q(a))^2$
 - Alternativamente, $V(a) = \frac{1}{N(a)} \sum_{i=1}^{N(a)} r_i^2 - (Q(a))^2$
 - Esta última fórmula puede ser computacionalmente más estable y conveniente en algunos casos.
- Expresión incremental:

1. Actualización del Promedio Incremental dado el promedio anterior Q_N y la nueva recompensa r_{N+1} :

$$Q_{N+1} = Q_N + \frac{r_{N+1} - Q_N}{N + 1}$$

2. Actualización de la Varianza Incremental.

$$V_{N+1} = V_N + \frac{(r_{N+1} - Q_N)(r_{N+1} - Q_{N+1})}{N + 1}$$

2'. Actualización de la Varianza Incremental.

1. Mantener dos sumas acumuladas:
 - Suma de las recompensas: $S_N = \sum_{i=1}^N r_i$
 - Suma de los cuadrados de las recompensas: $S_N^{(2)} = \sum_{i=1}^N r_i^2$
2. Actualizar las sumas:
 - $S_{N+1} = S_N + r_{N+1}$
 - $S_{N+1}^{(2)} = S_N^{(2)} + r_{N+1}^2$
3. Actualizar la varianza V_{N+1} :

$$V_{N+1} = \frac{S_{N+1}^{(2)}}{N + 1} - \left(\frac{S_{N+1}}{N + 1} \right)^2$$

Más variantes UCB

- ▶ **UCB-Improved o UCB-V (UCB-Variance)** Valor $\text{UCB-Improved}(a) = Q(a) + \sqrt{\frac{\sigma(a)^2 \ln t}{N(a)}}$
 - ▶ $\sigma(a)^2$: varianza estimada de las recompensas para la acción a .
- ▶ **UCB with Decaying Exploration** Valor $\text{UCB-Decay}(a) = Q(a) + \frac{c \ln t}{N(a)^\alpha}$
 - ▶ α : parámetro que controla la tasa de decaimiento de la exploración (usualmente $0 < \alpha < 1$).
- ▶ **UCB-Confidence Bound Adjustment (UCB-C)** Valor $\text{UCB-C}(a) = Q(a) + \sqrt{\frac{\ln(t+1) + f(N(a))}{N(a)}}$
 - ▶ $f(N(a))$: función ajustable para cambiar el peso del término de exploración en función de $N(a)$, que puede depender del problema.



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Método Softmax

- ▶ ϵ -Greedy selecciona bandidos aleatoriamente, experimentando con todos con la misma probabilidad.
 - ▶ Ignora que algunas esperanzas medias crezcan más que otras.
- ▶ Idea: Asignar una probabilidad a cada acción proporcional al valor de la recompensa esperada actual.

Función de Gibbs (softmax):
$$P(A_t = a) = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^k e^{Q_t(b)/\tau}} = \pi_t(a)$$

$$\Pr(x_i) = \frac{e^{-\frac{E(x_i)}{kT}}}{\sum_j e^{-\frac{E(x_j)}{kT}}}$$

Algoritmo 9 Algoritmo Softmax para el Problema del Bandido Multibrazo

- 1: **Inicialización:**
- 2: Para cada acción a , establecer la recompensa promedio inicial $Q_0(a) = 0$
- 3: Establecer una valor $\tau > 0$
- 4: **for** cada tiempo $t = 1, 2, 3, \dots$ **do**
- 5: **for** cada tiempo $k = 1, 2, \dots, K$ (número de brazos) **do**
- 6: Calcular las probabilidades de selección para cada acción a : $\pi_t(a) = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^k e^{Q_t(b)/\tau}}$
- 7: **end for**
- 8: Seleccionar una acción A_t de acuerdo con la distribución de probabilidad $\pi_t(a)$
- 9: Recibir la recompensa R_t correspondiente a la acción A_t
- 10: Actualizar la recompensa promedio: $Q_t(a) = Q_{t-1}(a) + \frac{1}{k}(R_t - Q_{t-1}(a))$
- 11: **end for**

Método de Gradiente de Preferencias

► En Sutton y Barto, 2018 se propone utilizar $\pi_t(a) = \frac{e^{H_t(a)}}{\sum_{b=1}^K e^{H_t(b)}}$

- $H_t(a) \in \mathbb{R}$ es una preferencia numérica para cada acción a
- A mayor preferencia (no recompensa), más frecuente se tomará la acción.

► Objetivo: aprender $H_t(a)$ mediante Método del Ascenso de Gradiente Estocástico.

$$\theta_{t+1} = \theta_t(x_t) + \alpha \nabla f(\theta_t, x_t) \implies H_{t+1}(a) = H_t(a) + \alpha \frac{\partial E[R_t]}{\partial H_t(a)} \text{ con } E[R_t] = \sum_x \pi_t(x) q(x)$$

► Actualizar las preferencias para cada acción tras seleccionar la acción A_t y recibir la recompensa R_t :

$$H_{t+1}(A_t) = H_t(A_t) + \alpha(R_t - \bar{R}_t)(1 - \pi_t(A_t)), \text{ y}$$

$$H_{t+1}(a) = H_t(a) - \alpha(R_t - \bar{R}_t)\pi_t(a), \text{ para todo } a \neq A_t$$



Profundizamos en ...

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Muestreo de Thomson

► Es un método alternativo a los métodos optimistas frente a la incertidumbre.

► Thompson, W. R., 1933 propone

... although serious objection can otherwise be raised to argument based upon a small number of observations. Indeed, the fact that such objection can never be eliminated entirely—no matter how great the number of observations— suggested the possible value of seeking other modes of operation than that of taking a large number of observations before analysis or any attempt to direct our course.

- Y es que la estadística bayesiana estaba muy mal vista
- Recomendado: Carmen Armero et al. (2022).

► **Planteamiento bayesiano.**

1. Modelar cada opción $a \in A$ con una distribución de probabilidad $P(\theta_a)$, donde:
 - θ_a representa el parámetro de éxito de la opción.
2. En cada iteración:
 - Seleccionar la mejor opción de acuerdo a su distribución de probabilidad
 - Considerar el nuevo dato observado D_a
 - Aplicar T. Bayes $P(\theta_a|D_a) = \frac{P(D_a|\theta_a)P(\theta_a)}{P(D_a)}$

Bandit de Bernoulli con Perspectiva Bayesiana

► $k \in 1, \dots, K$. Tenemos K -acciones.

► $r_k \sim \text{Bernoulli}(\theta_k)$

► $\theta = (\theta_1, \dots, \theta_K)$ es desconocida pero fija en el tiempo (no cambia).

► $r_k \in \{0, 1\}$ es la recompensa obtenida al seleccionar la acción k ,

► $\theta_k \in [0, 1]$ es la probabilidad de éxito asociada a la acción k ,

► $\text{Bernoulli}(\theta_k)$ denota la distribución Bernoulli con parámetro θ_k .

$$P(r_k = 1 | \theta_k) = \theta_k, \quad P(r_k = 0 | \theta_k) = 1 - \theta_k.$$

► 1. $\forall k \quad r_k \sim \mathbb{P}(\theta_k)$

2. $x_1 \mapsto r_1 \in \{0, 1\} \mapsto P(r_1 | x_1, \theta) = \theta_1$

3. $x_2 \mapsto r_2 \in \{0, 1\} \mapsto P(r_2 | x_1, \theta_1) = \theta_2$

4. etc ...

► **Inicialmente**, el parámetro θ_k será uniforme (al azar). $\theta_k \sim U(0, 1) = \text{Beta}(\alpha_k = 1, \beta_k = 1)$

$$p(\theta_k) = \frac{\Gamma(\alpha_k + \beta_k)}{\Gamma(\alpha_k)\Gamma(\beta_k)} \theta_k^{\alpha_k-1} (1 - \theta_k)^{\beta_k-1} \quad \Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt.$$

► La distribución se actualiza según la **Regla de Bayes**: $f(\theta|x) \propto L(x|\theta)f(\theta)$

Si $\theta \sim \text{Beta}(\alpha, \beta)$, $L(x|\theta) \sim \text{Bernoulli}(\theta)$, entonces $\theta|x \sim \text{Beta}(\alpha + x, \beta + 1 - x)$

► **Regla de actualización:**

$$(\alpha_k, \beta_k) \leftarrow \begin{cases} (\alpha_k, \beta_k) & \text{si } x_t \neq k, \\ (\alpha_k, \beta_k) + (r_t, 1 - r_t) & \text{si } x_t = k. \end{cases}$$

Algorithm 10 Greedy para Beta-Bernoulli

Entrada: K, α, β

```
1: for  $t = 1, 2, \dots$  do
2:   # Estimar modelo:
3:   for  $k = 1, \dots, K$  do
4:      $\hat{\theta}_k \leftarrow \frac{\alpha_k}{\alpha_k + \beta_k}$ 
5:   end for
6:
7:   # Seleccionar y aplicar acción:
8:    $x_t \leftarrow \arg \max_k \hat{\theta}_k$ 
9:   Aplicar  $x_t$  y observar  $r_t$ 
10:
11:  # Actualizar distribución:
12:   $(\alpha_{x_t}, \beta_{x_t}) \leftarrow (\alpha_{x_t} + r_t, \beta_{x_t} + 1 - r_t)$ 
13: end for
```

Algorithm 11 Muestreo de Thompson para Beta-Bernoulli

Entrada: K, α, β

```
1: for  $t = 1, 2, \dots$  do
2:   # Muestrear modelo:
3:   for  $k = 1, \dots, K$  do
4:     Muestrear  $\hat{\theta}_k \sim \text{Beta}(\alpha_k, \beta_k)$ 
5:   end for
6:
7:   # Seleccionar y aplicar acción:
8:    $x_t \leftarrow \arg \max_k \hat{\theta}_k$ 
9:   Aplicar  $x_t$  y observar  $r_t$ 
10:
11:  # Actualizar distribución:
12:   $(\alpha_{x_t}, \beta_{x_t}) \leftarrow (\alpha_{x_t} + r_t, \beta_{x_t} + 1 - r_t)$ 
13: end for
```

Ejemplo:

$$\theta_1 = 0,9$$


$$\theta_2 = 0,8$$

$$\theta_3 = 0,7$$


10000

simulaciones

$T = 1000$



(a) greedy algorithm



(b) Thompson sampling

Muestreo de Thompson General

■ Componentes del problema general:

- ▶ Acciones: $x_1, x_2, x_3, \dots \in X$
- ▶ Tras una acción x_t , se observa un resultado $y_t \sim q_\theta(\cdot|x_t)$.
- ▶ θ es incierta, pero tiene su propia distribución $\theta \sim p$
- ▶ Se obtiene una recompensa $r_t = r(y_t)$, con r función conocida.

En Beta-Bernoulli: $r(y) = y$, $y_t = r_t \sim q_\theta = \text{Bern}(\theta)$ y $\theta \sim p = \text{Beta}(1, 1)$

■ Recompensa esperada para $\hat{\theta}$: $\mathbb{E}_{q_{\hat{\theta}}}[r(y_t)|x_t = x] = \sum_o q_{\hat{\theta}}(o|x)r(o)$.

■ Teorema de Bayes: $p \leftarrow P_{p,q}(\theta = u|x_t, y_t) = \frac{p(u)q_u(y_t|x_t)}{\sum_v p(v)q_v(y_t|x_t)}$.

Algorithm 12 Greedy(X, p, q, r)

```

1: for  $t = 1, 2, \dots$  do
2:   Estimar modelo:  $\hat{\theta} \leftarrow \mathbb{E}_p[\theta]$ 
3:   Seleccionar y aplicar acción:
4:    $x_t \leftarrow \arg \max_{x \in X} \mathbb{E}_{q_{\hat{\theta}}}[r(y_t)|x_t = x]$ 
5:   Aplicar  $x_t$  y observar  $y_t$ 
6:   Actualizar distribución:  $p \leftarrow P_{p,q}(\theta \in \cdot | x_t, y_t)$ 
7: end for

```

Algorithm 13 Thompson(X, p, q, r)

```

1: for  $t = 1, 2, \dots$  do
2:   Muestrear modelo: Muestrear  $\hat{\theta} \sim p$ 
3:   Seleccionar y aplicar acción:
4:    $x_t \leftarrow \arg \max_{x \in X} \mathbb{E}_{q_{\hat{\theta}}}[r(y_t)|x_t = x]$ 
5:   Aplicar  $x_t$  y observar  $y_t$ 
6:   Actualizar distribución:  $p \leftarrow P_{p,q}(\theta \in \cdot | x_t, y_t)$ 
7: end for

```



Con más detalle ..

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

► Recuerda:

- $ucb(a) = Q(a) + u(a)$
- Término de explotación, $Q(a)$ (el promedio de las recompensas)
- Término de exploración, $u(a)$ (límite superior)
- $a_t = \arg \max_{a \in A} ucb(a)$

► Si conocemos la distribución, usar $ucb(a) = \mu(a) + \gamma\sigma(a)$

- $\mu(a)$ es la media de recompensas obtenidas por a .
- $\sigma(a)$ es la desviación estándar de la distribución.
- γ determina el número de desviaciones.

► Ejemplo. Si $a \sim \text{Beta}(\alpha, \beta)$, se sabe que $\mu(a) = \frac{\alpha}{\alpha+\beta}$ y que $\sigma(a) = \sqrt{\frac{\alpha \cdot \beta}{(\alpha+\beta)^2 \cdot (\alpha+\beta+1)}}$

Con lo que el índice de cada decisión vendrá dada por:

$$ucbbayes(a) = \frac{\alpha_j}{\alpha_j + \beta_j} + \gamma \cdot \sqrt{\frac{\alpha_j \cdot \beta_j}{(\alpha_j + \beta_j)^2 \cdot (\alpha_j + \beta_j + 1)}}$$



Desarrollo

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

► Conclusiones principales:

- El problema del bandido multibrazos es clave para entender la toma de decisiones bajo incertidumbre.
- Algoritmos como el greedy son simples pero efectivos en contextos limitados.
- Métodos avanzados ofrecen mejores resultados, especialmente cuando la exploración es crítica.
- La elección del algoritmo depende del equilibrio entre precisión, eficiencia y contexto específico.

► Aplicaciones:

- Publicidad en línea (A/B testing).
- Optimización de sistemas en tiempo real.
- Sistemas de recomendación y más.



Desarrollo

1. El Problema del Bandido Multibrazos
 - 1.1. Planteamiento del problema
 - 1.2. Ejemplos del problema del bandido multibrazos
2. Soluciones al Problema del Bandido
 - 2.1. Round-Robin
 - 2.2. Métodos acción-valor
 - 2.3. Algoritmo greedy
 - 2.4. Implementación incremental
 - 2.5. Añadiendo Exploración
 - ϵ -greedy
 - Métodos optimistas
 - ϵ -decaimiento
 - 2.6. Métodos índice
 - Midiendo la eficiencia
 - Métodos UCB (Upper Confidence Bound)
 - 2.7. Métodos de Ascenso del Gradiente
 - 2.8. Métodos Bayesianos
 - Muestreo de Thomson
 - UCB Bayesiano
3. Conclusiones
4. Referencias

Referencias – I



Agrawal, R. (1995). Sample mean based index policies by $O(\log n)$ regret for the multi-armed bandit problem. *Advances in Applied Probability*, 27(4), 1054–1078. <https://doi.org/10.2307/1427934>



Bonald, T. (2017). Reinforcement Learning: Multi-Armed Bandits. <https://perso.telecom-paristech.fr/bonald/documents/bandit.pdf>



Carmen Armero, Patricia Rodríguez & José M. de la Torre Hernández. (2022). Una pequeña mirada a la estadística bayesiana en el análisis de datos cardiológicos. *REC: Interventional Cardiology*, 4(3), 207–215. <https://doi.org/10.24875/RECIC.M22000284>



Daniel J. Russo, Benjamin Van Roy, Abbas Kazerouni, Ian Osband & Zheng Wen. (2018). A Tutorial on Thompson Sampling. *Foundations and Trends® in Machine Learning*, 11(1), 1–96. <https://doi.org/10.1561/22000000070>



Lai, T. L., & Robbins, H. (1985). Asymptotically efficient adaptive allocation rules. *Advances in Applied Mathematics*, 6(1), 4–22. [https://doi.org/10.1016/0196-8858\(85\)90002-8](https://doi.org/10.1016/0196-8858(85)90002-8)



Lane, D. R. A. (2021). Librería Python para resolver el bandido multibrazo (Multi-armed bandit). <https://www.analyticslane.com/2021/06/25/libreria-python-para-resolver-el-bandido-multibrazo-multi-armed-bandit/>



Peter Auer, Nicolò Cesa-Bianchi & Paul Fischer. (2002). Finite-time Analysis of the Multiarmed Bandit Problem. *Machine Learning*, 47(2–3), 235–256. <https://doi.org/10.1023/A:1013689704352>



Referencias – II



Robbins, H. (1952). Some Aspects of the Sequential Design of Experiments. *Bulletin of the American Mathematical Society*, 58(5), 527–535. <https://doi.org/10.1090/S0002-9904-1952-09620-8>



Silver, D. (2015). RL Course by David Silver – Lecture 9: Exploration and Exploitation. <https://www.youtube.com/watch?v=sGuiWX07sKw>



Sutton, R., & Barto, A. (2018). *Reinforcement Learning, second edition: An Introduction*. MIT Press. <https://web.stanford.edu/class/psych209/Readings/SuttonBartoPRLBook2ndEd.pdf>



Thompson, W. R. (1933). On the likelihood that one unknown probability exceeds another in view of the evidence of two samples. *Biometrika*, 25, 285–294. <https://doi.org/10.1093/biomet/25.3-4.285>